

Yue CAO

+33 7 75 79 78 10 | yuec1963@gmail.com | 2063mmz | yue-cao | Paris, France

EXPÉRIENCE PROFESSIONNELLE

Berger-Levrault - Lab I5.0

Févr 2026 – Août 2026

Stagiaire de recherche

France

Générateur Intelligent de Packs d'Assistance pour la Maintenance Industrielle Hors-Ligne

- Prototypage d'un système générant automatiquement des packs d'assistance compacts pour des *tiny LLM* hors-ligne déployés sur appareils mobiles, à destination des techniciens de maintenance en environnement déconnecté, sous contraintes de confidentialité, de latence et de ressources
- Analyse d'ordres de travail afin d'identifier les besoins documentaires et sélection des contenus les plus pertinents parmi des sources hétérogènes (PDF techniques, documents, images, historique d'interventions)
- Construction, maintenance et mise à jour des packs hors-ligne : préparation du *chunking*, génération des embeddings, des index et des métadonnées requis par le moteur hors-ligne existant dans son format standard, en tenant compte des contraintes de contexte des *tiny LLM*
- Optimisation de la qualité des packs par compression, déduplication, priorisation et indicateurs simples de qualité, afin de ne conserver que les contenus les plus utiles dans une enveloppe de taille restreinte
- Conception et test d'un pipeline RAG pour les packs générés, et intégration au flux de déploiement ONNX de l'assistant Android hors-ligne existant, afin d'évaluer la pertinence, la cohérence, le temps de réponse et le comportement sur mobile

FORMATION

INALCO – PluriTAL

Sept. 2025 – Présent

Master 2 en Traitement Automatique des Langues

Paris, France

- **Enseignements** : Apprentissage automatique, Réseaux de neurones, Modèles de langue, Programmation algorithmique, Programmation et programmation objets, Technologies du Web, Linguistique pour le TAL multilingue

Université Paris Nanterre – PluriTAL

Sept. 2024 – Juin 2025

Master 1 en Traitement Automatique des Langues

Nanterre, France

- **Enseignements** : Traitement de corpus, Statistique textuelle, Mathématiques, Corpus parallèles, Treebanks et analyse syntaxique, Fouille de textes, Documents structurés, SQL

Université Internationale du Heilongjiang

Sept. 2020 – Juin 2024

Licence de Langue et Littérature Françaises

Heilongjiang, Chine

- **mémoire de fin d'études** : Analyse des méthodes de traduction de métaphore dans les langues familières à l'exemple du feuilleton français *Dix pour Cent*

PROJETS

Pipeline RAG pour Question-Réponse

2026

- Construction d'un *pipeline* RAG complet avec ChromaDB et Gemini pour la réponse à des questions portant sur le roman *L'Amie prodigieuse*

Modèles Transformer pour le chinois classique

2026

- Entraînement *from scratch* de Transformers de type BERT et GPT pour la classification de genres et la génération de texte en chinois classique ; expérimentations sur la prose historique et la poésie des Tang

Classification d'images sur CIFAR-10 avec un CNN

2026

- Entraînement et évaluation d'un CNN sur CIFAR-10 avec PyTorch, avec amélioration des performances par ajustement de l'architecture et raffinement de l'entraînement
- Application d'augmentation de données, *shuffling* des mini-lots et stratégies d'optimisation basées sur ReLU pour améliorer les résultats de classification

Prévision du trafic urbain parisien à partir de séries temporelles trafic et météo

2026

- Pipeline de prévision du trafic urbain parisien à court terme, combinant les comptages multimodaux de Paris Open Data et les variables météo de l'API Open-Meteo. Le projet couvre le prétraitement des données JSON, la fusion trafic-météo, la construction de variables calendaires avec encodage cyclique (sin/cos), puis l'entraînement et la comparaison de quatre approches : baseline historique, HistGradientBoosting, LSTM et GRU. Restitution via une application Streamlit.

COMPÉTENCES

Programmation : Python (pandas, NumPy, scikit-learn, Keras, NLTK, spaCy, Stanza, Word2Vec, Hugging Face Transformers), SQL, Bash/Shell, HTML, CSS, XML

Deep Learning : CNN, RNN, LSTM/GRU, architectures Transformer (BERT, GPT)

Tâches TAL : RAG, classification de sentiments, *topic modeling*, génération de texte, extraction d'information, OCR, ASR, TTS, synthèse vocale

Outils : VS Code, Jupyter, Overleaf, Oxygen XML, MySQL, Praat, Tesseract, Unitex, marimo, neo4j, NooJ

Langues : Chinois (langue maternelle), Français (courant / professionnel), Anglais (courant / professionnel)