




CAO Yue

Je m'appelle CAO Yue, étudiante en NLP, curieuse, avec un bon esprit d'initiative et une bonne capacité à travailler en équipe. Patiente, stable et posée, grande capacité d'apprentissage et recherche active d'informations, adaptation facile aux environnements académiques et techniques.



yuec1963@gmail.com
 +33 7 75 79 78 10
 <https://github.com/2063mmz>
 [linkedin](#)
 [huggingface](#)

Formations

MASTER TAL (NLP) – R&D

09/2025 – en cours Deuxième année
INALCO – PluriTAL

MASTER TAL (NLP)

09/2024 – 06/2025 Première année
Université Paris Nanterre – PluriTAL

LICENCE LANGUE ET LITTÉRATURE FRANÇAISES

2020 – 2024
Université International du Heilongjiang,
Heilongjiang, Chine

Cours Principaux

Apprentissage automatique;
Réseaux de neurones profonds;
Programmation algorithmes;
Fouille de textes;
Statistique textuelle;
Corpus arborés et parsing;
Bases de données;

langues parlées

Chinois : langue maternelle
Français : B2/C1
Anglais : B2/C1

Projets pratiques principaux

ENTRAÎNEMENT DE MODÈLES TRANSFORMER POUR LA CLASSIFICATION ET LA GÉNÉRATION DE CHINOIS CLASSIQUE

Entraînement from scratch d'un classificateur de genre et de modèles génératifs en architecture Transformer (type BERT/GPT) pour identifier le genre d'un texte et générer du chinois classique, expérimentation sur prose historique et poésie Tang.

PIPELINE RAG

Développé un pipeline RAG complet. Création d'un mini système RAG avec ChromaDB et Gemini pour le question-réponse sur un roman.

CONSTRUCTION D'UN AI AGENT AVEC SCRIPTS PYTHON

Développement d'un agent simple sans framework : analyse d'entrées utilisateur, sélection d'outils, extraction et restitution des résultats (météo, calculs, test de personnage de jeu). Déploiement d'une interface Web via Gradio sur Hugging Face.

CLASSIFICATION D'IMAGES CIFAR-10 À L'AIDE D'UN CNN

Entraînement d'un CNN sur CIFAR-10 avec PyTorch et évaluation de ses performances. Les résultats sont ensuite améliorés par l'ajustement de l'architecture et du processus d'entraînement (augmentation de données, mini-lots avec mélange aléatoire et fonction d'activation ReLU) afin d'obtenir les meilleures performances possibles sur CIFAR-10.

Compétences

Python : pandas, NumPy, scikit-learn, NLTK, spaCy, Stanza, THULAC, Word2Vec; **Deep Learning** : Keras, PyTorch;

Données : HTML, XML, CSV, JSON

SQL et **Bash/Shell**

Deep Learning: CNN, RNN (LSTM, GRU), Seq2Seq+Attention, Transformer

Logiciels et outils : VS Code, Jupyter Notebook, Oxygen XML, MySQL, Unifex, Praat, marimo, Overleaf, Tesseract5

Tâches réalisées : classification de sentiments, génération, extraction, synthèse vocale, ASR, TTS, OCR, RAG